《机器学习基础》

卷积神经网络

https://github.com/styluck/mech_learn

全连接前馈神经网络

- 权重矩阵的参数非常多

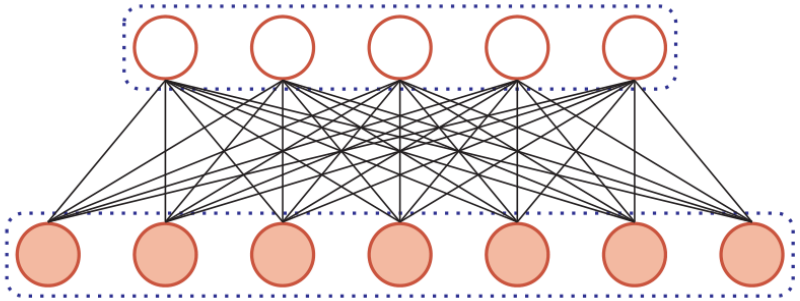

- 局部不变性特征
  - 自然图像中的物体都具有局部不变性特征
    - 尺度缩放、平移、旋转等操作不影响其语义信息。
  - 全连接前馈网络很难提取这些局部不变特征

卷积神经网络

- 卷积神经网络（Convolutional Neural Networks，CNN）
  - 一种前馈神经网络
  - 受生物学上感受野（Receptive Field）的机制而提出的
    - 在视觉神经系统中，一个神经元的感受野是指视网膜上的特定区域，只有这个区域内的刺激才能够激活该神经元。
  - 特别适用于处理具有网格拓扑结构的数据，如图像（2D网格）和时间序列数据（1D网格）
- 卷积神经网络有三个结构上的特性：
  - 局部连接
  - 权重共享
  - 空间或时间上的次采样

卷积

- 卷积经常用在信号处理中，用于计算信号的延迟累积。
- 假设一个信号发生器每个时刻t产生一个信号x_t，其信息的衰减率为w_k，即在$k-1$个时间步长后，信息为原来的w_k倍
  - 假设$w_1 = 1, w_2 = 1/2, w_3 = 1/4$
- 时刻t收到的信号y_t为当前时刻产生的信息和以前时刻延迟信息的叠加。

卷积

- 卷积经常用在信号处理中，用于计算信号的延迟累积。
- 假设一个信号发生器每个时刻t产生一个信号x_t，其信息的衰减率为w_k，即在$k-1$个时间步长后，信息为原来的w_k倍
  - 假设$w_1 = 1, w_2 = 1/2, w_3 = 1/4$
- 时刻t收到的信号y_t为当前时刻产生的信息和以前时刻延迟信息的叠加。

$$
\begin{aligned}
y_t &= 1 \times x_t + 1/2 \times x_{t-1} + 1/4 \times x_{t-2} \\
&= w_1 \times x_t + w_2 \times x_{t-1} + w_3 \times x_{t-2} \\
&= \sum_{k=1}^{3} w_k \cdot x_{t-k+1}.
\end{aligned}
$$

滤波器（filter）或卷积核（convolution kernel）

卷积

- 给定一个输入信号序列x和滤波器w,卷积的输出为:

$$y_t = \sum_{k=1}^{K} w_k x_{t-k+1}$$

Filter: [-1,0,1]

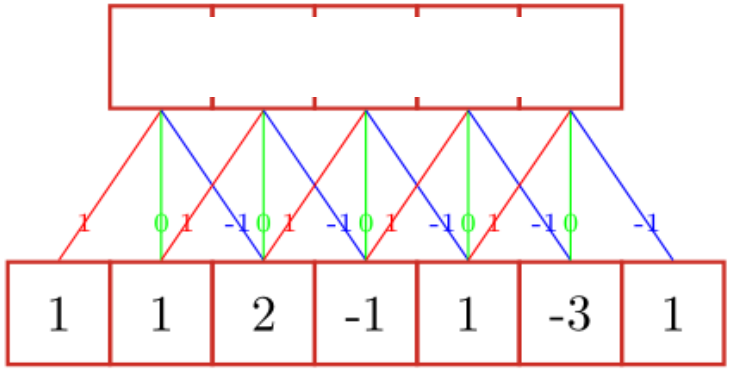

卷积

- 给定一个输入信号序列x和滤波器w,卷积的输出为:

$$y_t = \sum_{k=1}^{K} w_k x_{t-k+1}$$

Filter: [-1,0,1]

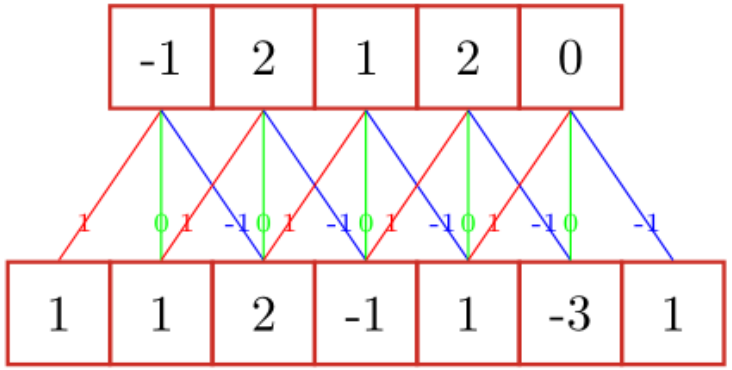

卷积的作用

- 不同的滤波器来提取信号序列中的不同特征

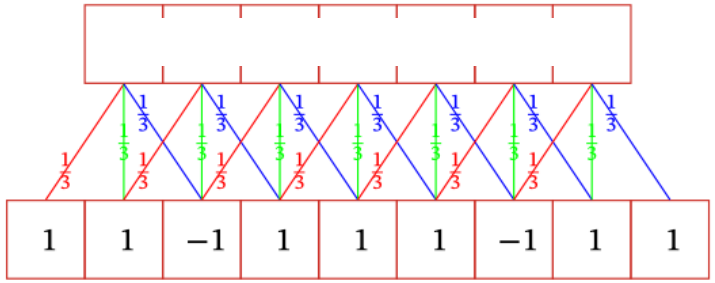

(a) 滤波器 [1/3, 1/3, 1/3]

低频信息

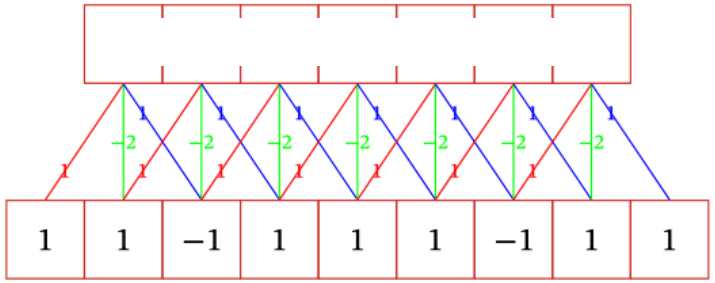

(b) 滤波器 [1, −2, 1]

高频信息

$$x''(t) = x(t+1) + x(t-1) - 2x(t)$$

二阶微分

卷积的作用

- 不同的滤波器来提取信号序列中的不同特征

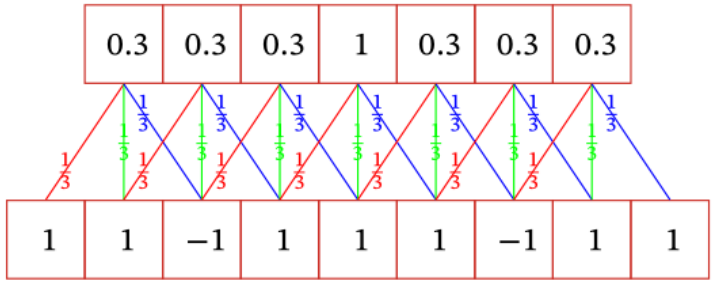

(a) 滤波器 [1/3, 1/3, 1/3]

低频信息

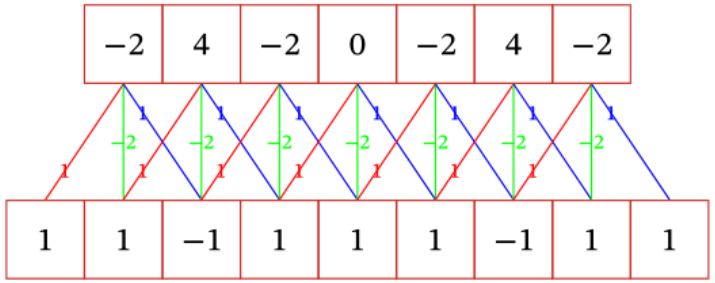

(b) 滤波器 [1, −2, 1]

高频信息

$$x''(t) = x(t+1) + x(t-1) - 2x(t)$$

二阶微分

卷积扩展

- 引入滤波器的滑动步长S和零填充P

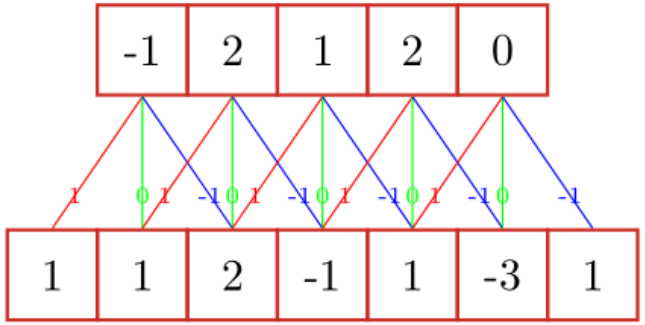

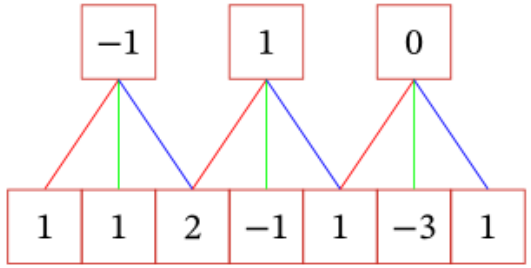

(a) 步长 $S = 2$

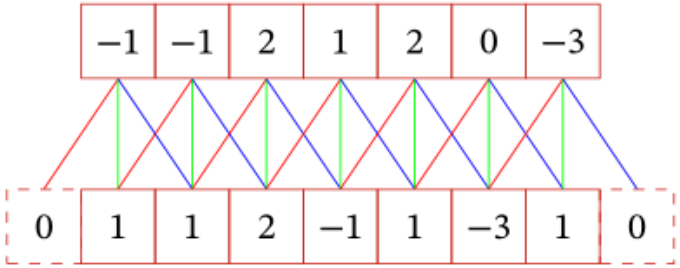

(b) 零填充 $P = 1$

卷积类型

- 卷积的结果按输出长度不同可以分为三类：
  - 窄卷积：步长 S = 1，两端不补零 $P = 0$，卷积后输出长度为
    $$M - K + 1$$
  - 宽卷积：步长 S = 1，两端补零 $P = K - 1$，卷积后输出长度为
    $$M + K - 1$$
  - 等宽卷积：步长 S = 1，两端补零 $P = (K - 1)/2$，卷积后输出长度为
    $$M$$

K：卷积长度
M：原始数据长度
S：步长
P：末端补零数

二维卷积

- 在图像处理中，图像是以二维矩阵的形式输入到神经网络中，因此我们需要二维卷积。

一个输入信息 $\boldsymbol{X}$ 和滤波器 $\boldsymbol{W}$ 的二维卷积定义为

$$\boldsymbol{Y} = \boldsymbol{W} * \boldsymbol{X},$$

$$y_{ij} = \sum_{u=1}^{U} \sum_{v=1}^{V} w_{uv} x_{i-u+1,j-v+1}.$$

$$\begin{bmatrix} 1 & 1 & \underset{\times -1}{1} & \underset{\times 0}{1} & \underset{\times 0}{1} \\ -1 & 0 & \underset{\times 0}{-3} & \underset{\times 0}{0} & \underset{\times 0}{1} \\ 2 & 1 & \underset{\times 0}{1} & \underset{\times 0}{-1} & \underset{\times 1}{0} \\ 0 & -1 & 1 & 2 & 1 \\ 1 & 2 & 1 & 1 & 1 \end{bmatrix} * \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & -1 \end{bmatrix} = \begin{bmatrix} 0 & -2 & -1 \\ 2 & 2 & 4 \\ -1 & 0 & 0 \end{bmatrix}$$

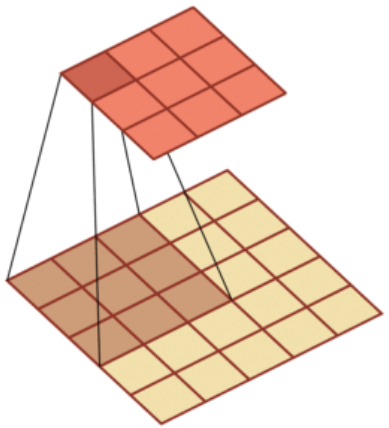

二维卷积

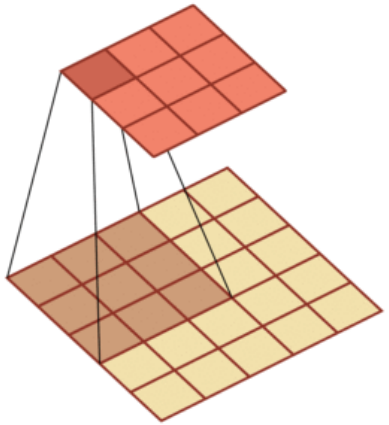

步长1，零填充0

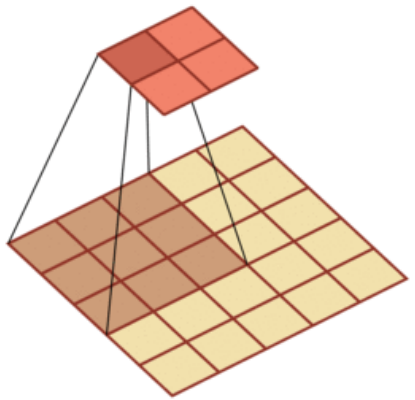

步长2，零填充0

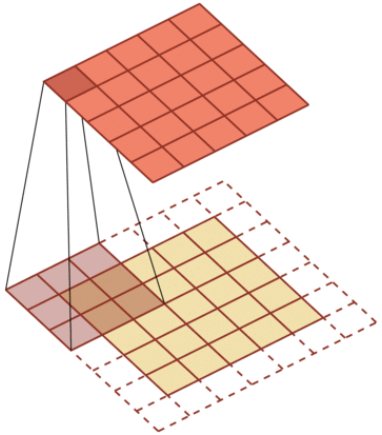

步长1，零填充1

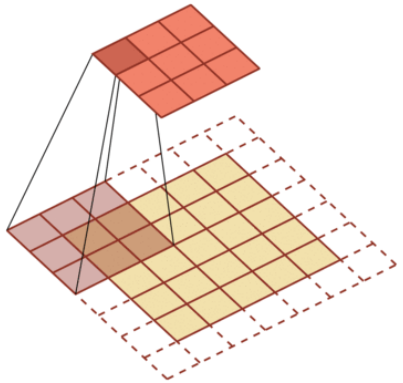

步长2，零填充1

卷积

卷积

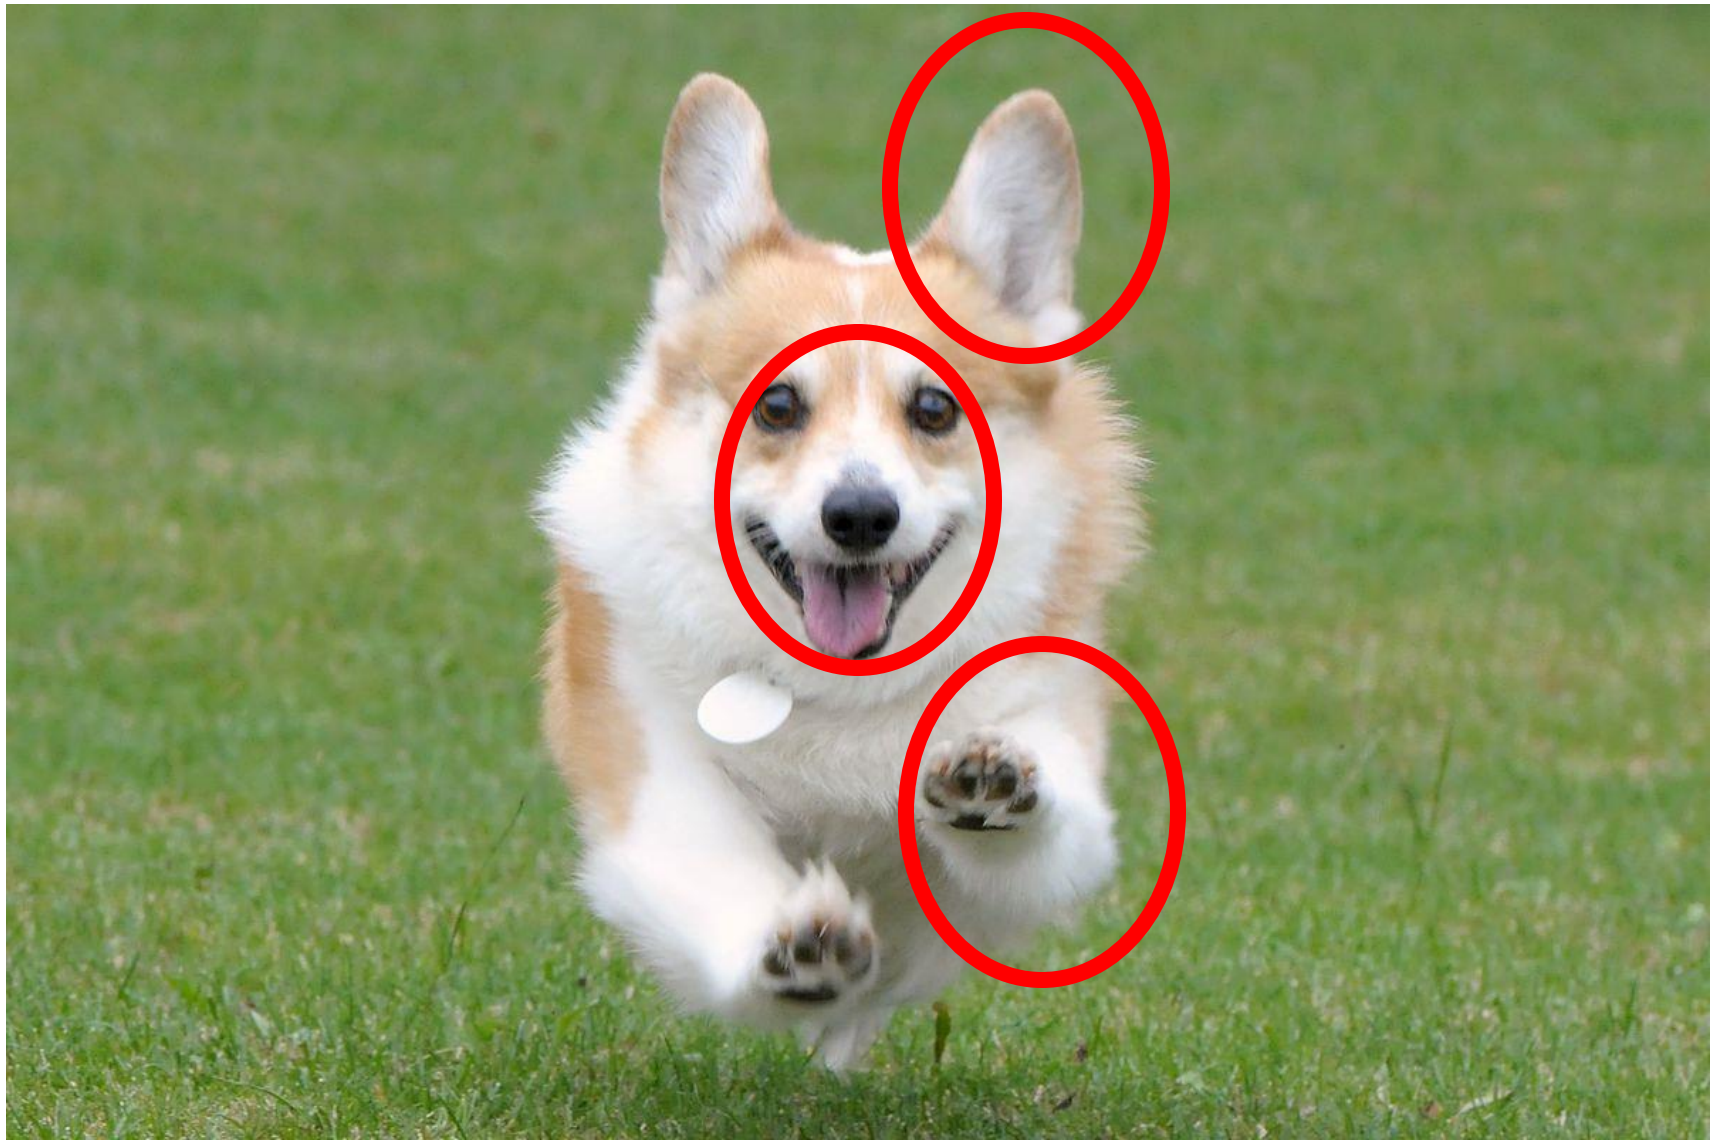

卷积

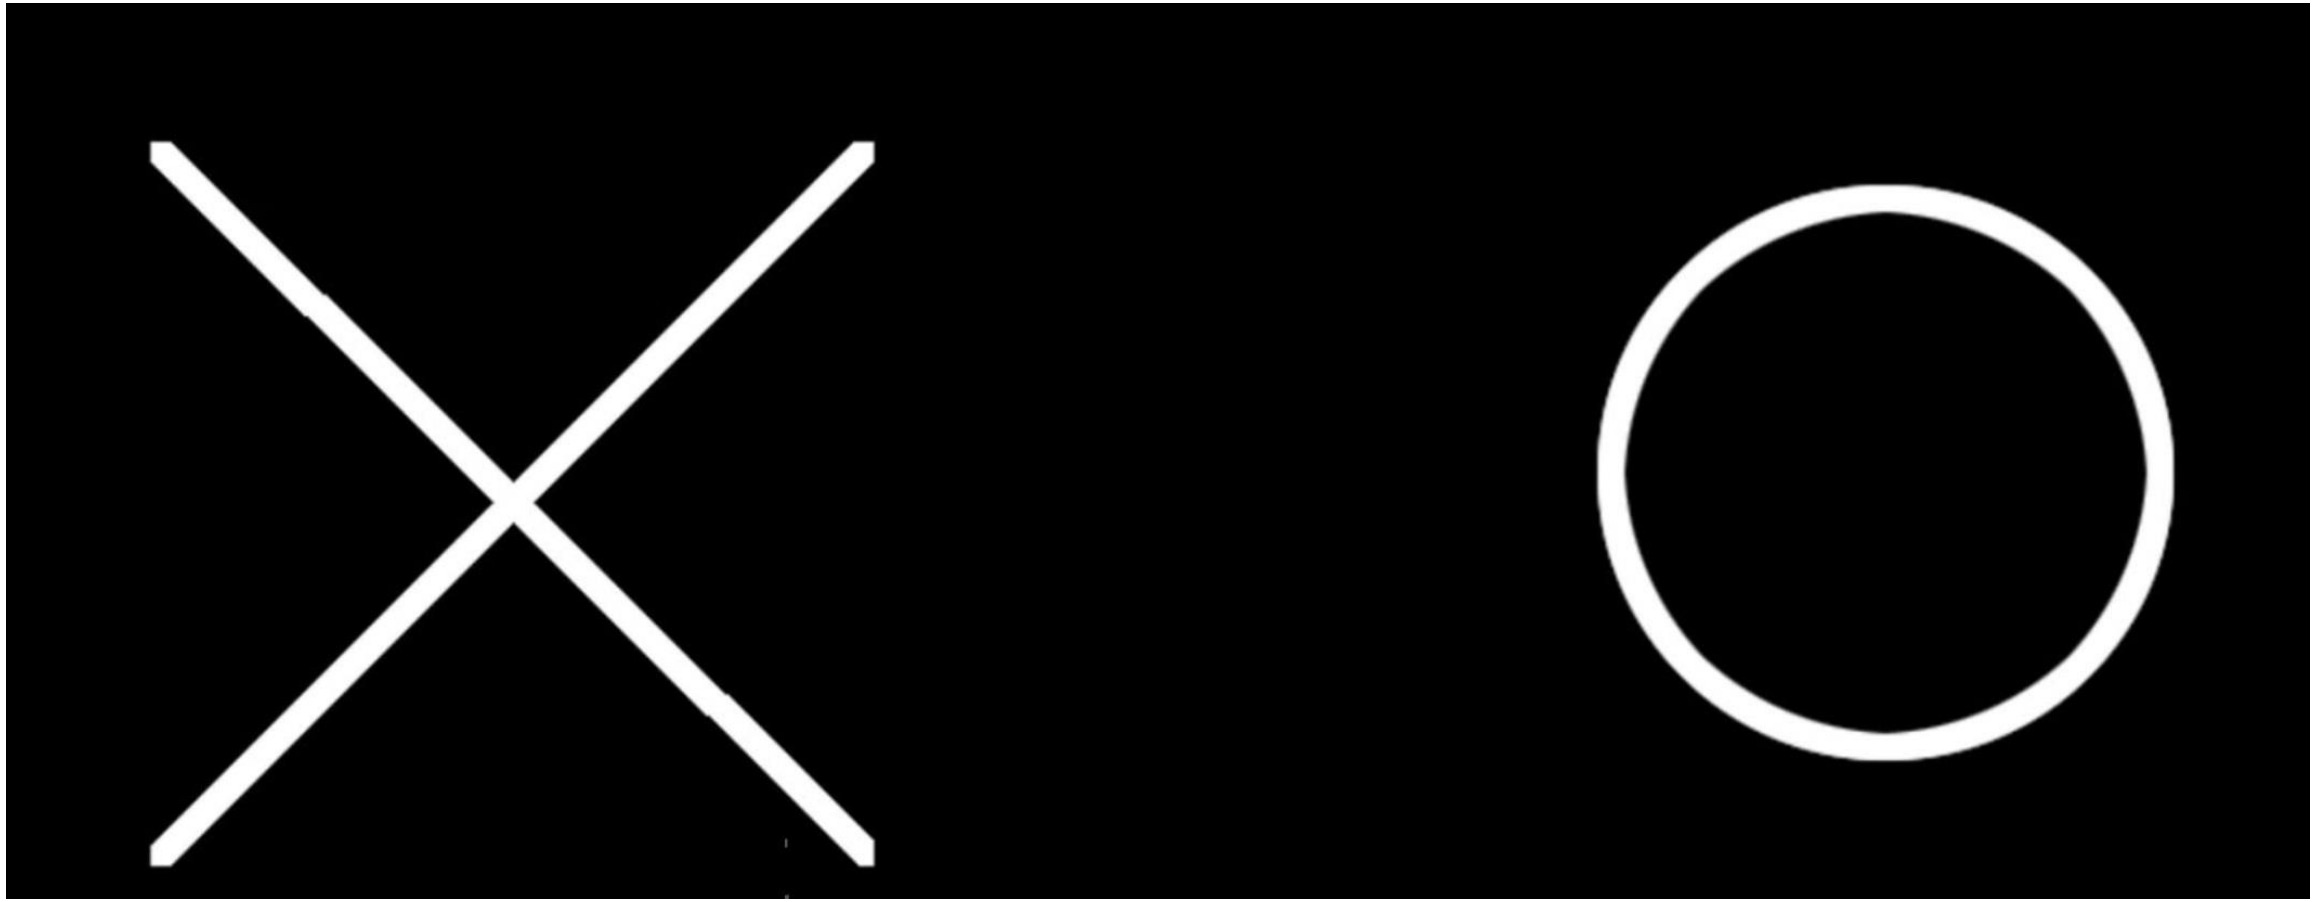

图解，卷积神经网络（CNN可视化）

卷积作为特征提取器

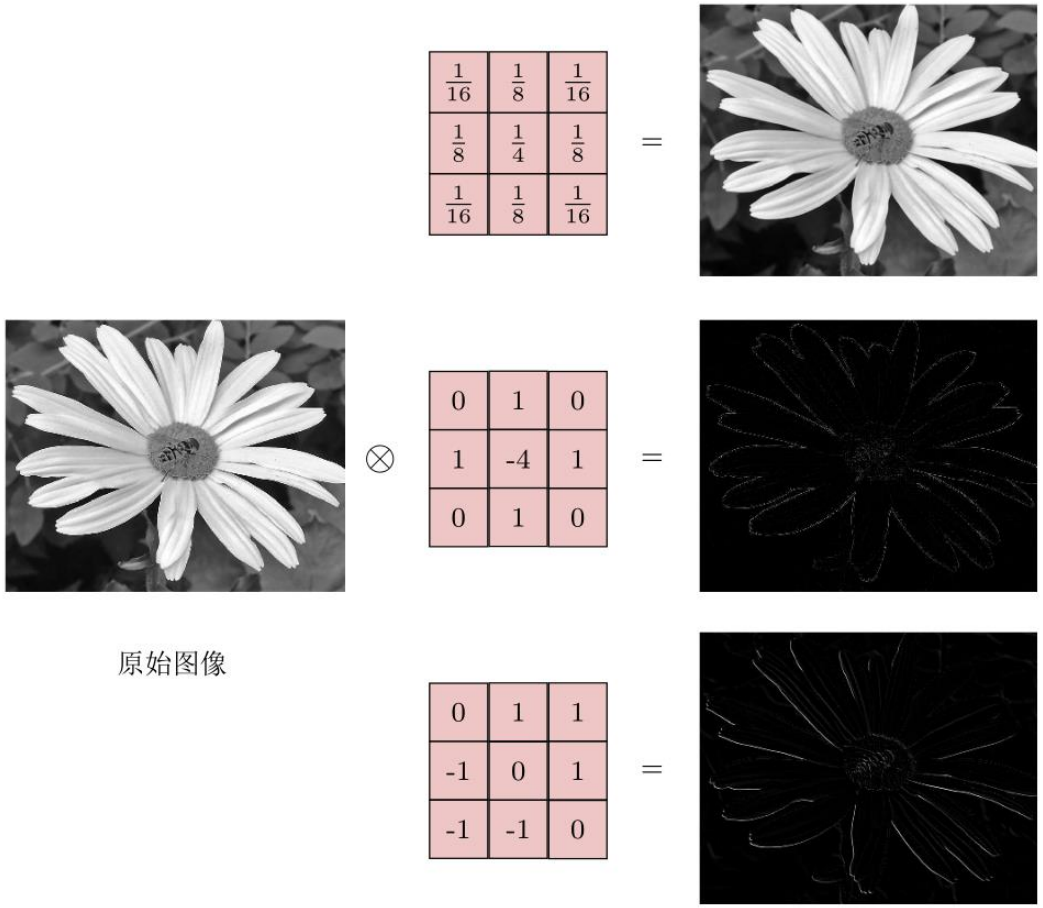
$\frac{1}{16}$ $\frac{1}{8}$ $\frac{1}{16}$
$\frac{1}{8}$ $\frac{1}{4}$ $\frac{1}{8}$
$\frac{1}{16}$ $\frac{1}{8}$ $\frac{1}{16}$
=
$\otimes$
0 1 0
1 -4 1
0 1 0
=
0 1 1
-1 0 1
-1 -1 0
=
原始图像
滤波器
输出特征映射

卷积神经网络

- 用卷积层代替全连接层

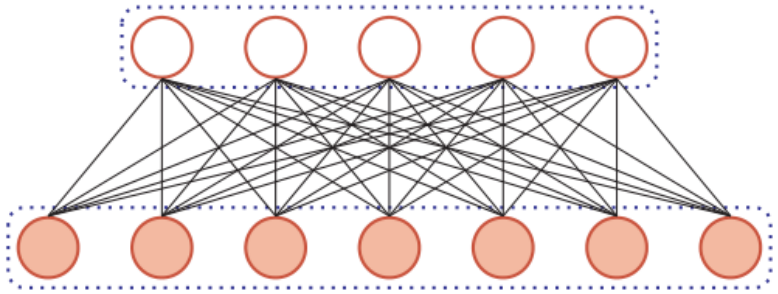

(a) 全连接层

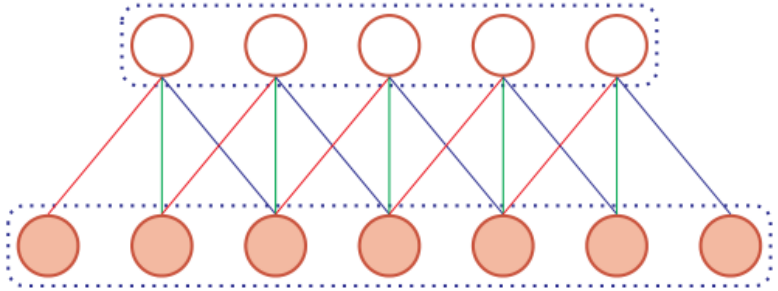

(b) 卷积层

$$y_{ij} = \sum_{u=1}^{m} \sum_{v=1}^{n} w_{uv} \cdot x_{i+u-1,j+v-1}$$

多个卷积核

- 特征映射（Feature Map）：图像经过卷积后得到的特征。
  - 卷积核看成一个特征提取器

- 卷积层
  - 输入：D个特征映射 $M \times N \times D$
  - 输出：P个特征映射 $M' \times N' \times P$

多个卷积核

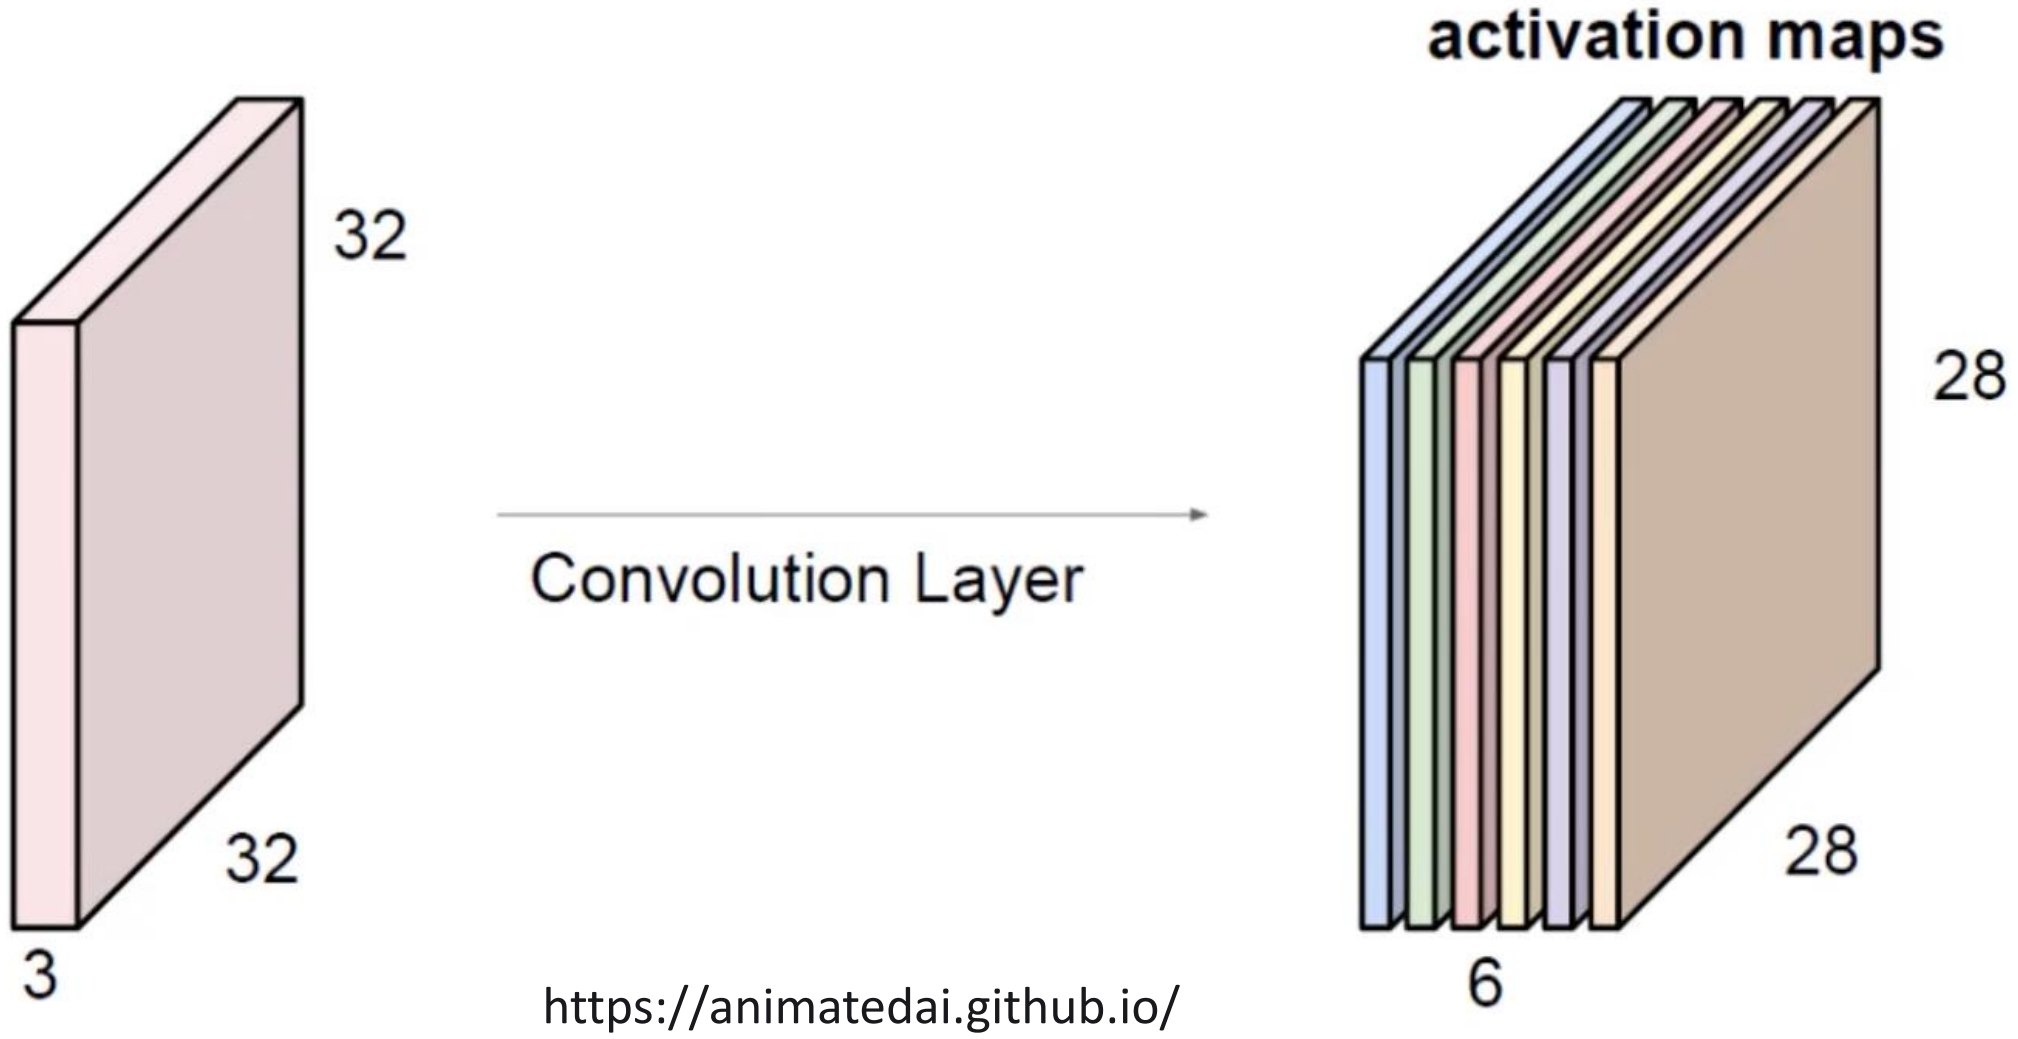

https://animatedai.github.io/

卷积层的映射关系

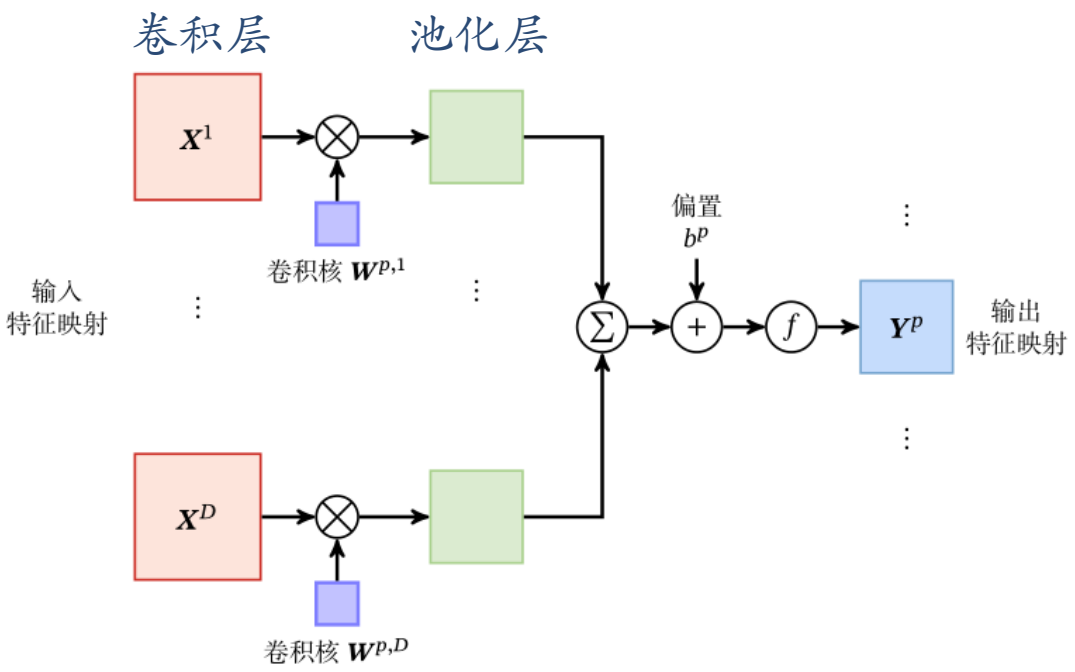

$$Z^p = W^p \otimes X + b^p = \sum_{d=1}^{D} W^{p,d} \otimes X^d + b^p,$$

$$Y^p = f(Z^p).$$

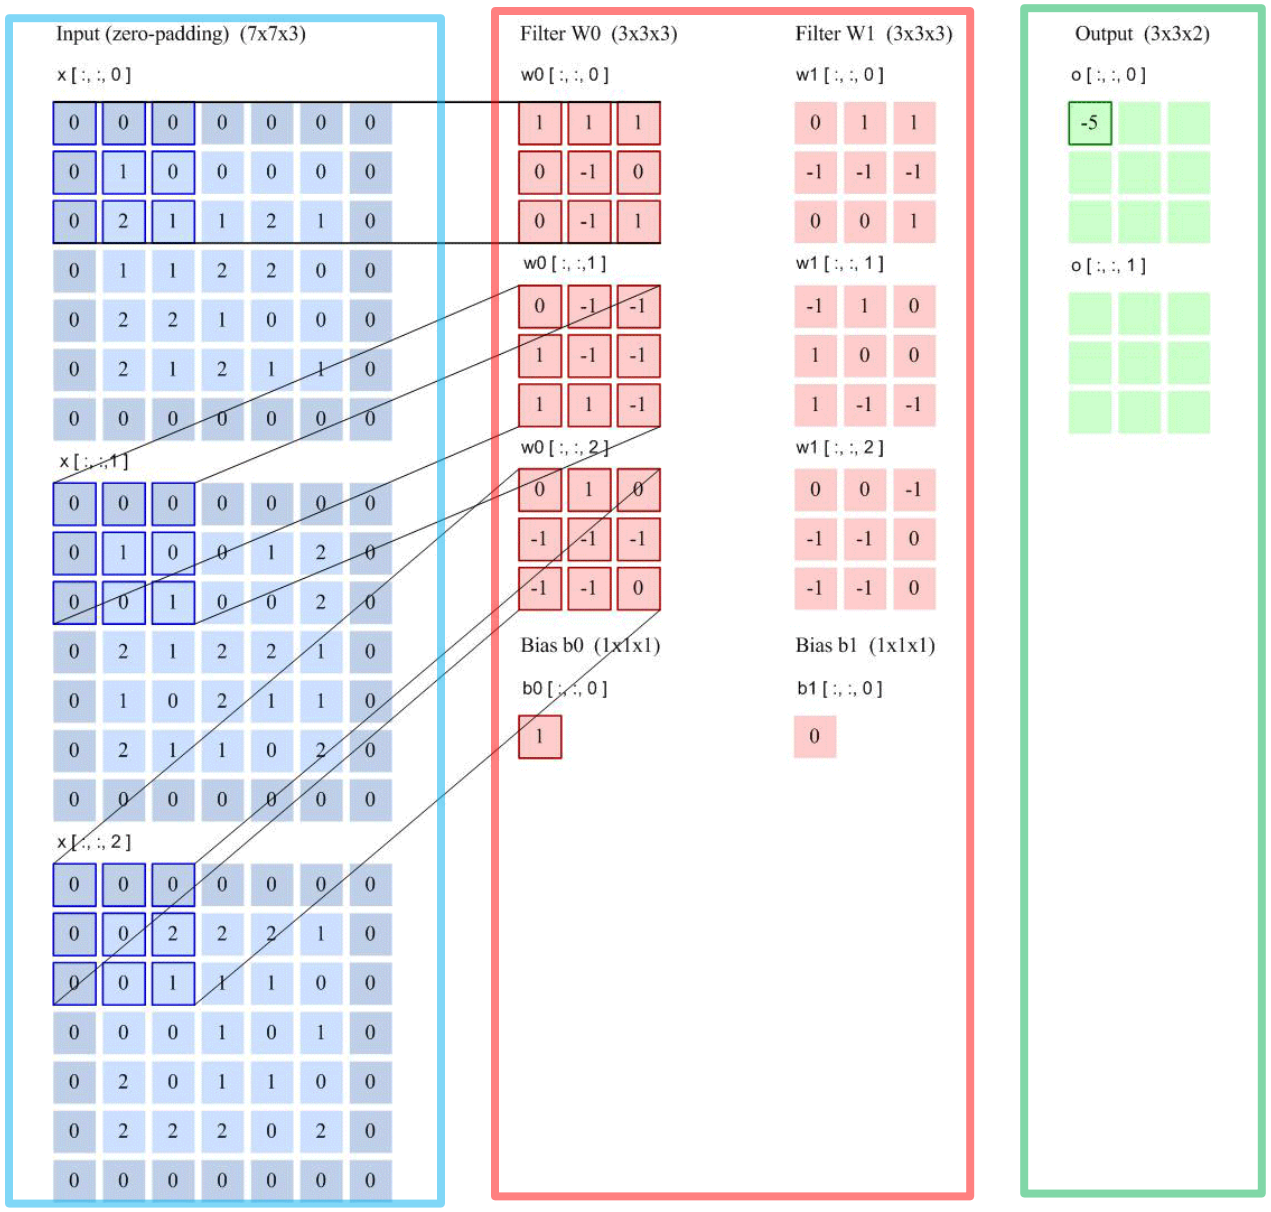

步长2
filter 3*3
filter个数6
零填充 1

卷积层

- 典型的卷积层为3维结构

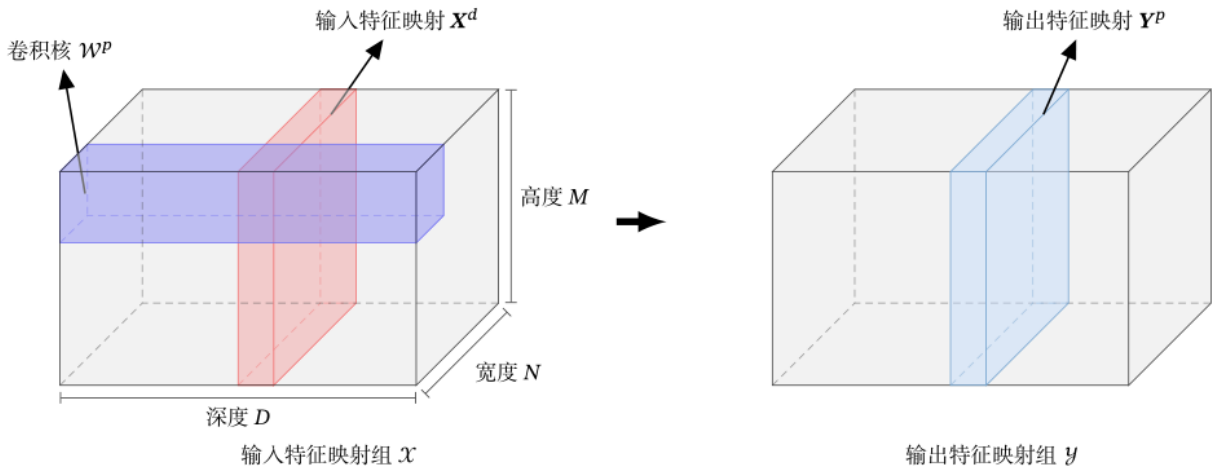

$$Z^p = W^p \otimes X + b^p = \sum_{d=1}^{D} W^{p,d} \otimes X^d + b^p,$$

$$Y^p = f(Z^p).$$

池化层/汇聚层

- 卷积层虽然可以显著减少连接的个数，但是每一个特征映射的神经元个数并没有显著减少。

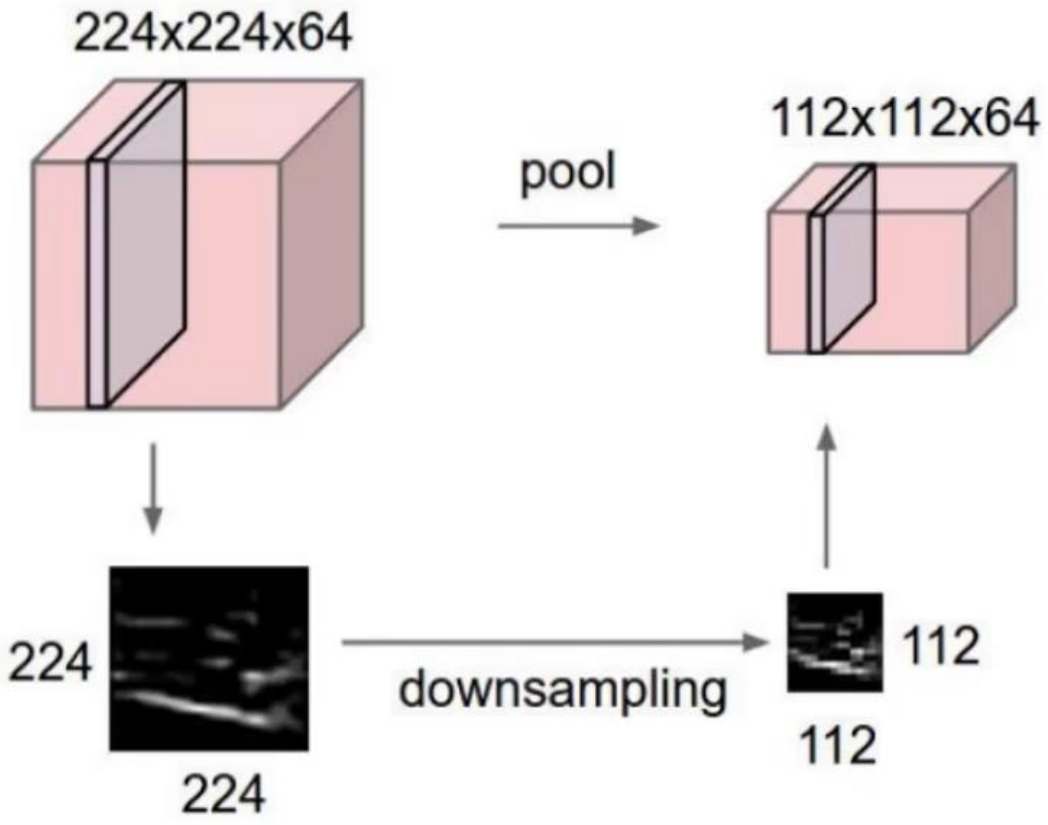

1	3	2	9
7	4	1	5
8	5	2	3
4	2	1	4

7	

池化层/汇聚层

- 卷积层虽然可以显著减少连接的个数，但是每一个特征映射的神经元个数并没有显著减少。

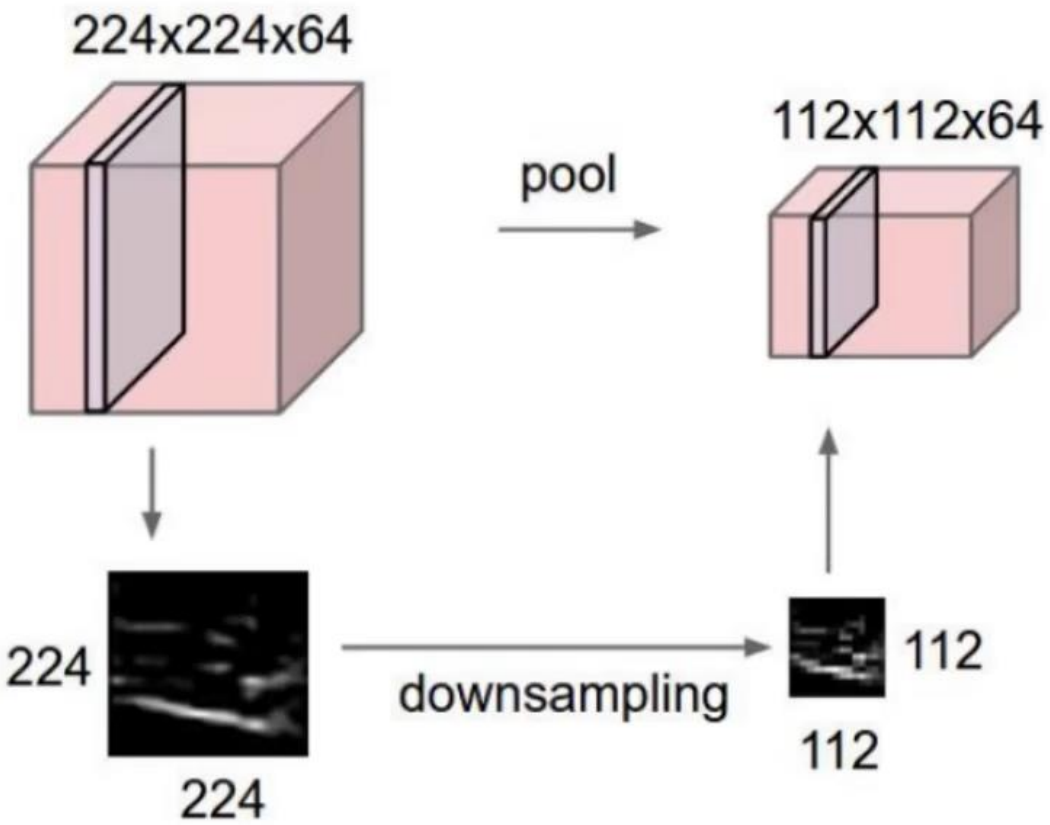

1	3	2	9
7	4	1	5
8	5	2	3
4	2	1	4

7	9
8	4

卷积神经网络

- 卷积层（Convolutional Layer）：卷积层通过一系列的卷积核（或滤波器）扫描输入数据，计算卷积核与输入数据局部区域的点积，从而提取特征。这些卷积核的参数在训练过程中学习得到，能够捕捉到输入数据中的重要特征。
- 池化层（Pooling Layer）：池化层用于降低特征图的空间尺寸，减少参数数量和计算量，同时保持特征的不变性。常见的池化操作有最大池化（Max Pooling）和平均池化（Average Pooling）。
- 全连接层（Fully Connected Layer）：在多个卷积和池化层之后，全连接层将学习到的特征映射到样本的标签空间，用于分类或回归任务。
- 丢弃层（Dropout Layer）：丢弃层在训练过程中随机丢弃一部分神经元的激活值，以防止过拟合，增强模型的泛化能力。

卷积网络结构

- 卷积网络是由卷积层、汇聚层(池化层)、全连接层交叉堆叠而成。

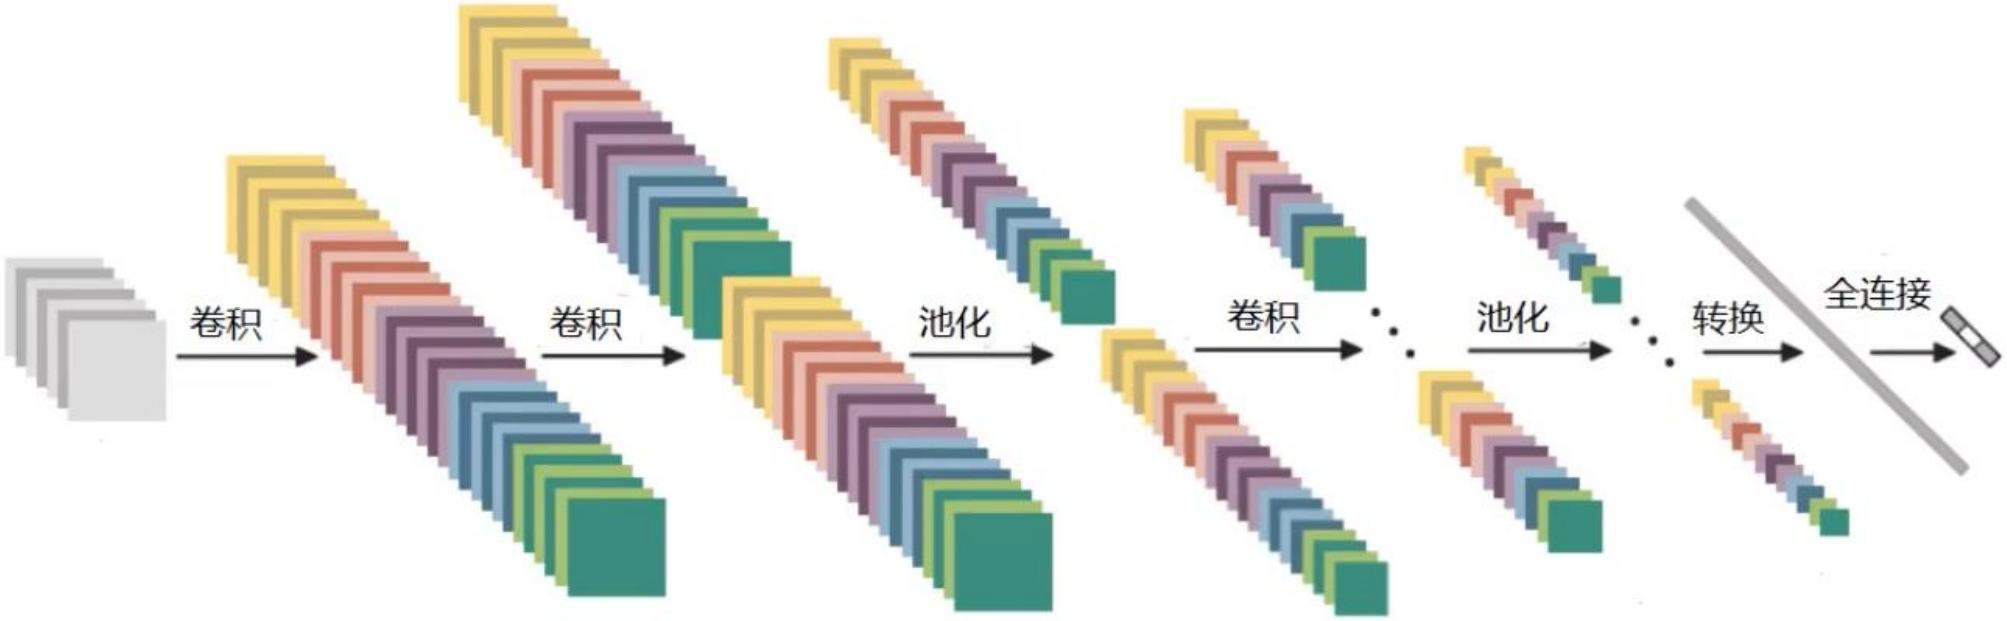

- 一个卷积块为连续M 个卷积层和b个池化层（M通常设置为2～5，b为0或1）。一个卷积网络中可以堆叠N 个连续的卷积块，然后在接着K 个全连接层（N 的取值区间比较大，比如1～100或者更大；K一般为0～2）。

卷积网络结构

- 卷积网络是由卷积层、汇聚层、全连接层交叉堆叠而成。
  - 趋向于小卷积、大深度
  - 趋向于全卷积
- 典型结构

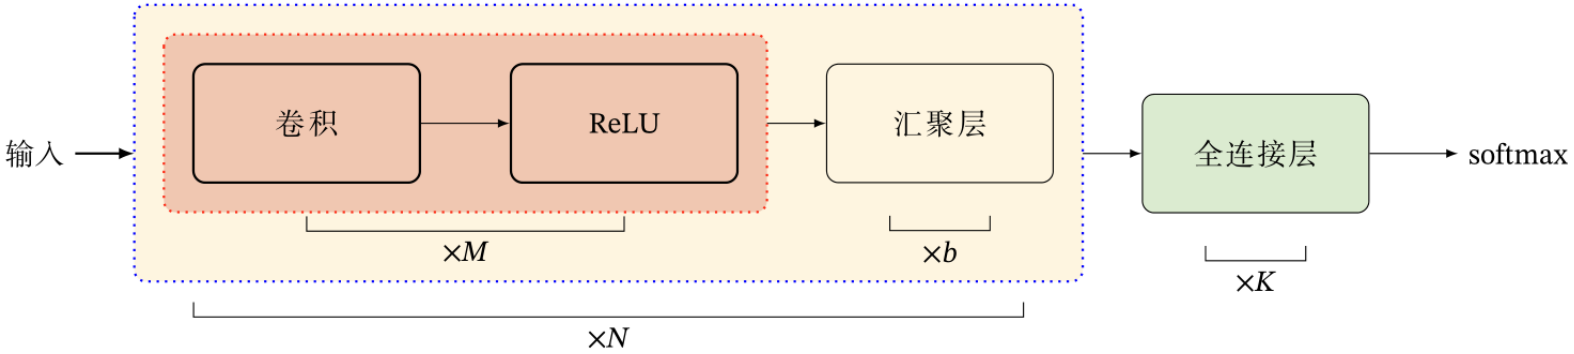

- 一个卷积块为连续M 个卷积层和b个汇聚层（M通常设置为2～5，b为0或1）。一个卷积网络中可以堆叠N 个连续的卷积块，然后在接着K 个全连接层（N 的取值区间比较大，比如1～100或者更大；K一般为0～2）。

表示学习

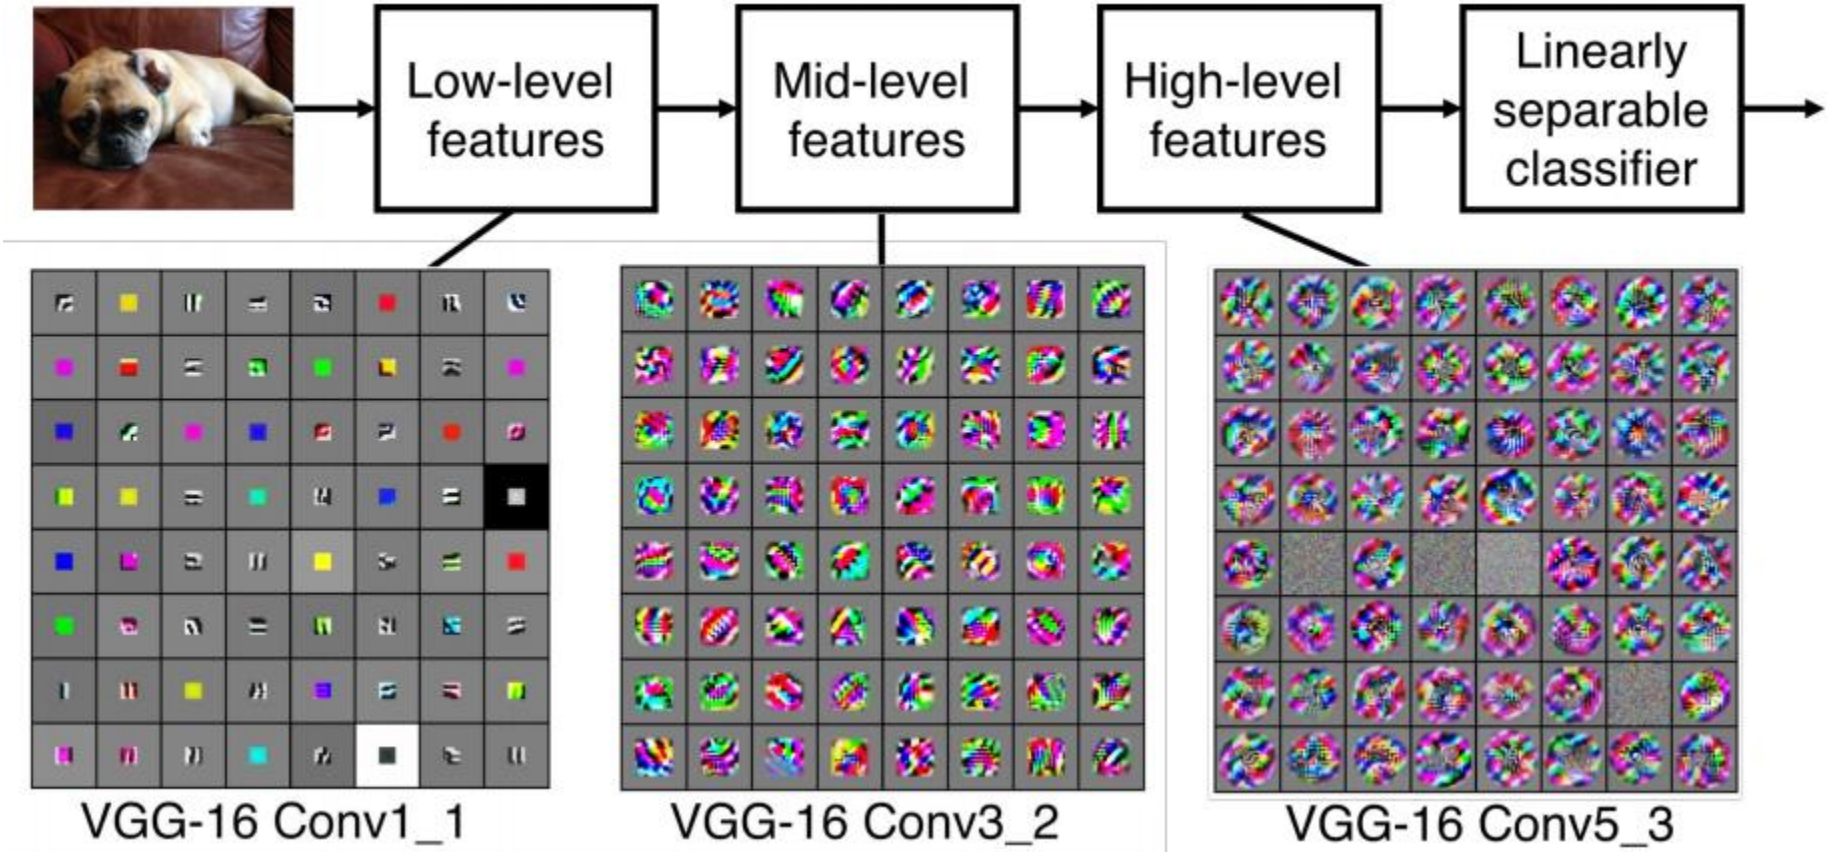
Low-level features
Mid-level features
High-level features
Linearly separable classifier
VGG-16 Conv1_1
VGG-16 Conv3_2
VGG-16 Conv5_3

卷积神经网络的BP算法

卷积神经网络的BP算法

a_1	a_2	a_3	a_4	a_5
a_6	a_7	a_8	a_9	a_{10}
a_{11}	a_{12}	a_{13}	a_{14}	a_{15}
a_{16}	a_{17}	a_{18}	a_{19}	a_{20}
a_{21}	a_{22}	a_{23}	a_{24}	a_{25}

w_1	w_2	w_3
w_4	w_5	w_6
w_7	w_8	w_9

z_1

$$z_1 = w_1 \times a_1 + w_2 \times a_2 + w_3 \times a_3 + w_4 \times a_6 \ \ldots \ w_9 \times a_{13}$$

卷积核也经常被叫做滤波器。在常规的前向传播过程中，我们从输入层的左上角开始。我们把卷积核中的权重和输入层中的对应值做乘法运算。

其它卷积种类

空洞卷积

- 如何增加输出单元的感受野
  - 增加卷积核的大小
  - 增加层数来实现
  - 在卷积之前进行汇聚操作

- 空洞卷积
  - 通过给卷积核插入“空洞”来变相地增加其大小。

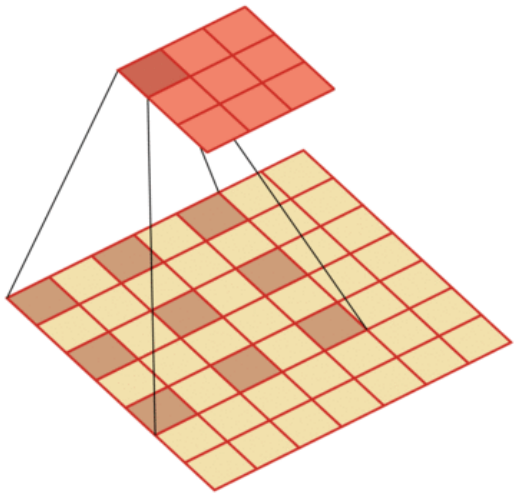

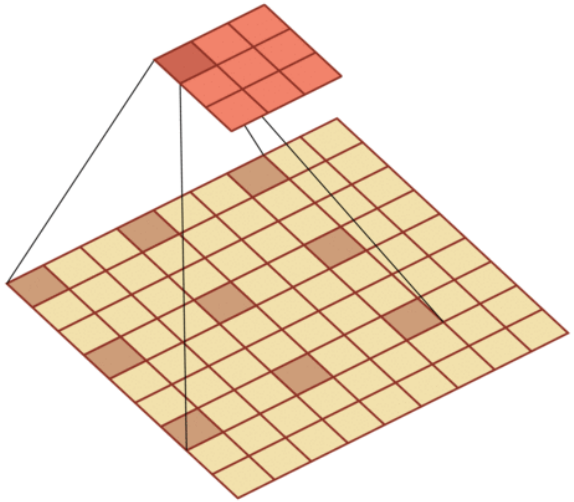

转置卷积/微步卷积

- 低维特征映射到高维特征

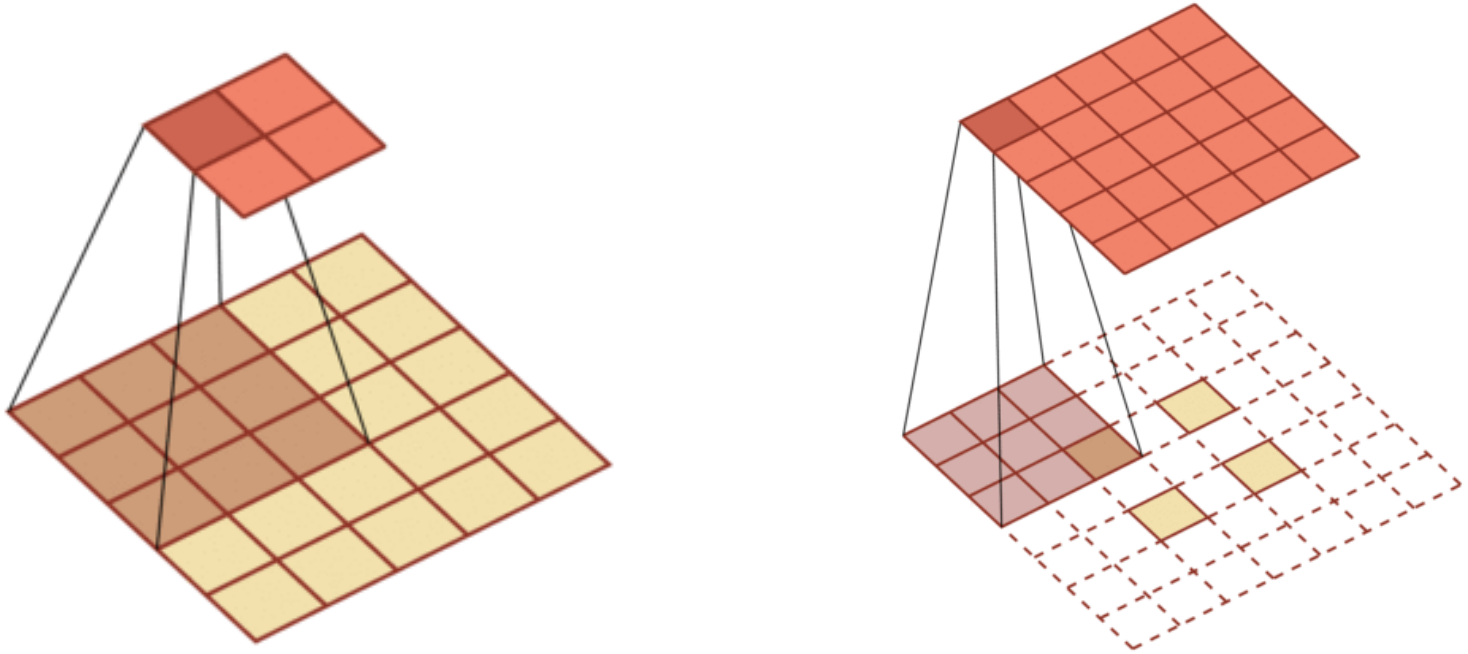

典型的卷积网络

LeNet-5

- LeNet-5 是一个非常成功的神经网络模型。
  - 基于 LeNet-5 的手写数字识别系统在 90 年代被美国很多银行使用，用来识别支票上面的手写数字。
  - LeNet-5 共有 7 层。

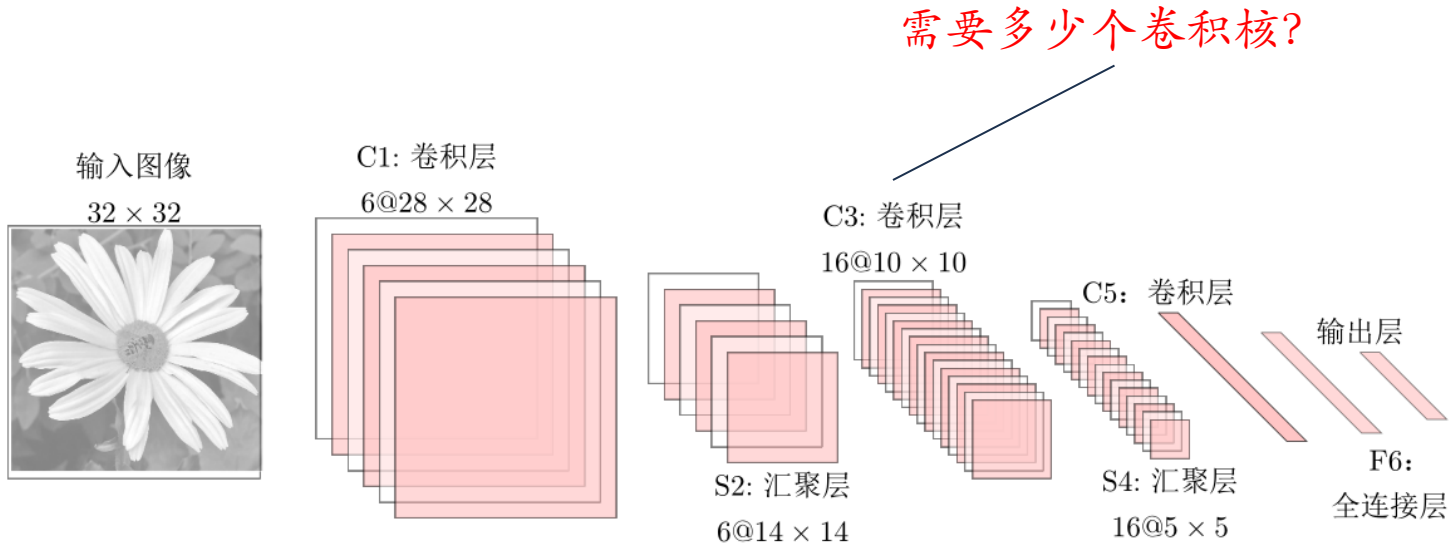

LeNet-5

- 1、输入层（Input layer）
  - 输入层接收大小为 的手写数字图像，包括灰度值（0-255）。
  - 归一化后数值区间（0-1）。
- 2、卷积层C1（Convolutional layer C1）
  - 包括6个卷积核，每个卷积核的大小为5x5，步长为1，填充为0，激活函数为sigmoid。
  - 卷积层C1会产生一个大小为28x28x6的特征图输出。
- 3、采样层S2（Subsampling layer S2）
  - 采用最大池化（max-pooling）操作，每个窗口的大小为2x2，步长为2。
  - 会产生一个大小为14x14x6的特征图输出。

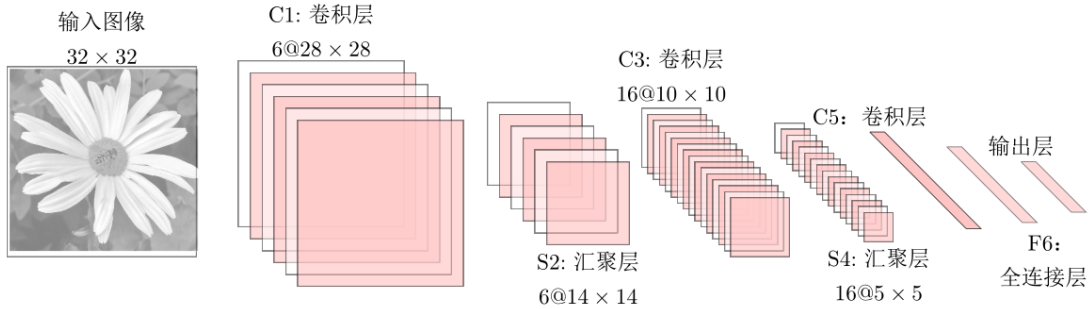

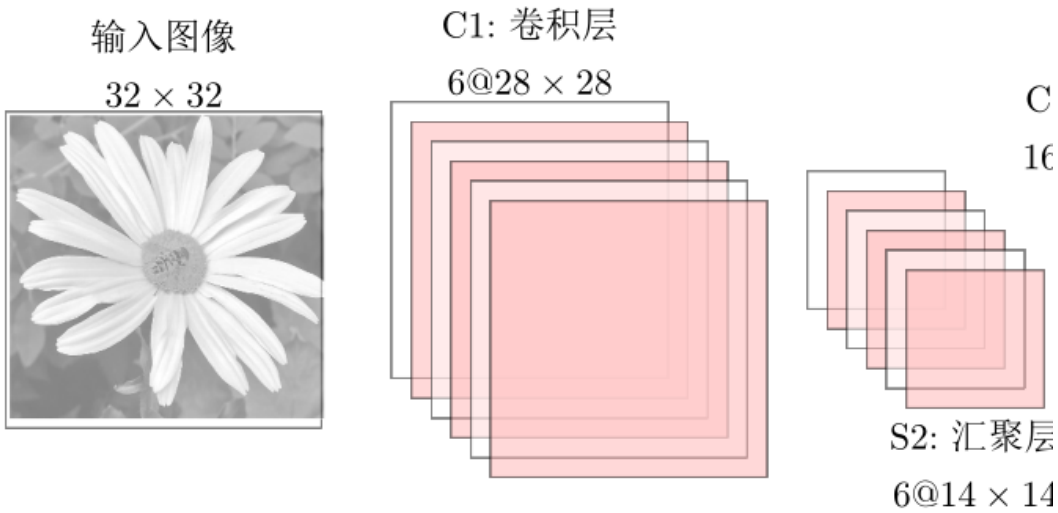

LeNet-5

- 4、卷积层C3（Convolutional layer C3）
  - 包括16个卷积核，每个卷积核的大小为5x5，步长为1，填充为0，激活函数为sigmoid。
  - 会产生一个大小为10x10x16的特征图输出。
- 5、采样层S4（Subsampling layer S4）
  - 采用最大池化操作，每个窗口的大小为2x2，步长为2。
  - 会产生一个大小为5x5x16的特征图输出。

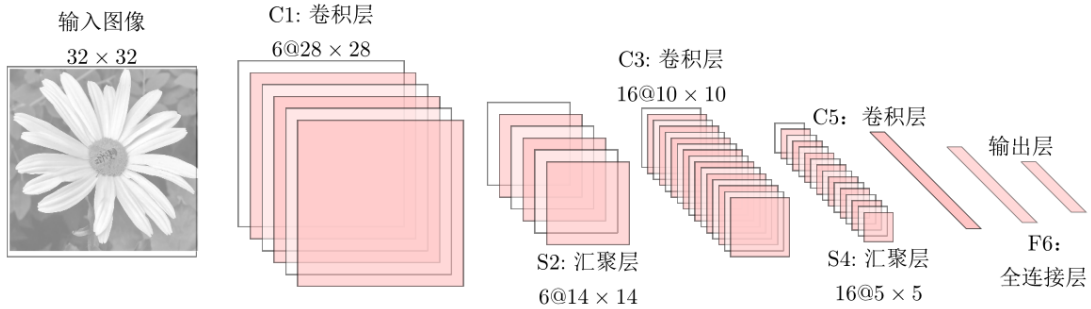

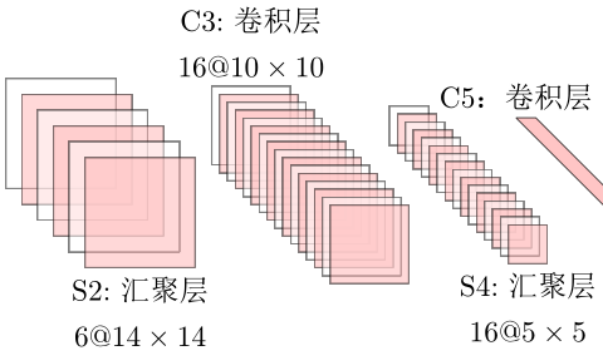

LeNet-5

- 6、全连接层C5（Fully connected layer C5）
  - 先将每个大小为5x5的特征图拉成一个长度为400的向量，并通过一个带有120个神经元的全连接层进行连接。
  - 120是由LeNet-5的设计者根据实验得到的最佳值。
- 7、全连接层F6（Fully connected layer F6）
  - 将120个神经元连接到84个神经元。
- 8、输出层（Output layer）
  - 输出层由10个神经元组成，每个神经元对应0-9中的一个数字，并输出最终的分类结果。
  - 使用交叉熵损失函数计算输出层的误差。
  - 通过反向传播算法更新卷积核和全连接层的权重参数。

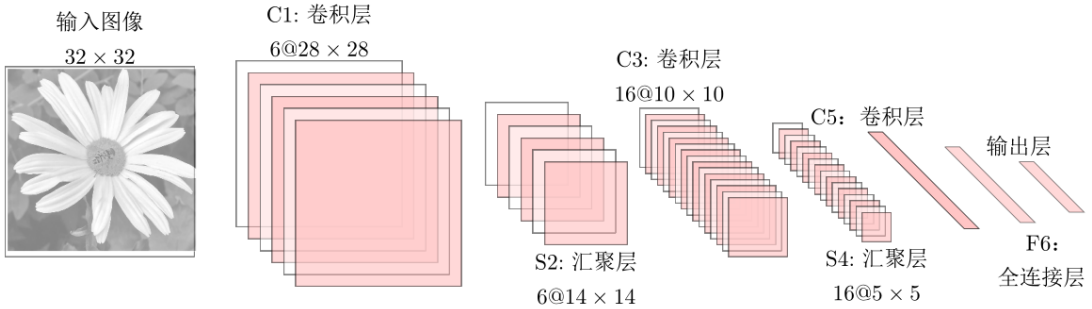

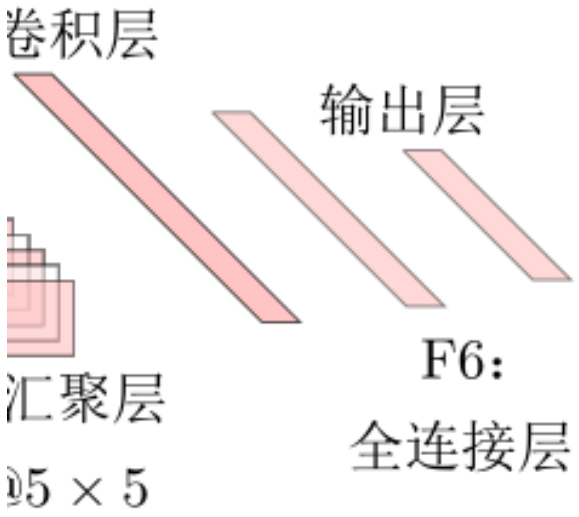

LeNet-5

C1层（第1个卷积层）：有6个5x5的卷积核，6x(5x5 + 1) = 156个参数。

C3层（第2个卷积层）：有16个5x5的卷积核，每个卷积核与上一层部分特征图相连。每个卷积核有5x5x6 = 150个参数，16个卷积核有16x(5x5x6 + 1) = 2,416个参数。

C5层（第3个卷积层）：可以看作是全连接层。5x5x16的特征图拉成一个长度为400的向量，连接到120个神经元，有120x(400 + 1) = 48,120个参数。

F6层（第1个全连接层）：输出120个特征连接到84个神经元，有84x(120 + 1) = 10,164个参数。

Output层（第2个全连接层）：输出84个特征连接到10个神经元，有10x(84 + 1) = 850个参数。

一共有156 + 2416 + 48120 + 10164 + 850 = 61,706个参数